



그래프의 숨겨진 언어를 해독하다

노드 분류와 링크 예측을 위한
인코더-디코더 프레임워크 및 실전 적용

유클리드 공간 / 고정된 구조



비유클리드 공간 / 불규칙한 위상




기존 딥러닝의 한계와 그래프 데이터의 본질

- **불규칙한 위상 (Irregular Topology):**
고정된 격자(Grid) 구조가 없어
전통적인 합성곱(CNN) 필터 적용 불가

- **순서 불변성 (Permutation Invariance):**
노드의 순서나 배열이 바뀌어도
그래프의 근본적인 의미와 구조는 동일

- **새로운 패러다임의 필요성:**
개별 데이터 포인트가 아닌,
'연결(Connection)' 자체를 학습하는 모델 요구

모든 GNN을 관통하는 단일 설계도: 인코더-디코더 프레임워크



Encoder (그래프 → 임베딩)

복잡한 구조와 속성을 저차원의 연속적인 벡터 공간(Z)으로 압축 변환

Decoder (임베딩 → 예측)

학습된 임베딩을 바탕으로 특정 다운스트림 작업(분류, 예측) 수행

핵심 엔진: 메시지 패싱 (MPNN) 메커니즘

네트워크 내의 정보가 이웃을 통해 파도처럼 전달되며 노드의 상태를 갱신합니다.



1. 메시지 생성 (Message)

이웃 노드와 엣지의 특성을
결합하여 전달할 정보 구성

2. 집계 (Aggregate)

순서 불변성을 유지하는 연산(Sum,
Mean, Max)으로 수신된 메시지 병합

3. 상태 업데이트 (Update)

이전 상태와 집계된 메시지를 결합하여
새로운 노드 임베딩 생성


인코더 쇼다운: 대표적인 GNN 아키텍처 비교


 GCN (Graph Convolutional Network)	 GAT (Graph Attention Network)	 GraphSAGE
작동 원리: 위상 구조에 기반한 정규화된 합산 (Normalized sum).	작동 원리: 어텐션 계수(α)를 통한 동적 중요도 학습.	작동 원리: 이웃의 고정 크기 샘플링 및 병합.
특징: 가장 구조적인 베이스라인. 학습 불가능한 고정된 집계 가중치 사용.	특징: 이웃마다 다른 가중치를 부여하여 노드 간의 복잡한 관계 집중 조명.	특징: 새로운 노드에 대한 일반화 가능. 대규모 그래프 처리에 최적화.
학습 환경: 변환적 (Transductive)	학습 환경: 변환적 & 귀납적	학습 환경: 귀납적 (Inductive)
수식: $\mathbf{H}^{(l+1)} = \sigma(\mathbf{D}^{-1/2} \mathbf{A} \mathbf{D}^{-1/2} \mathbf{H}^{(l)} \mathbf{W}^{(l)})$	수식: $\mathbf{h}_i^{(l+1)} = \sigma\left(\sum \alpha_{ij} \mathbf{W} \mathbf{h}_j^{(l)}\right)$	수식: $\mathbf{h}_i^{(l+1)} = \sigma(\mathbf{W} \cdot \text{CONCAT}(\mathbf{h}_i^{(l)}, \text{AGG}(\dots)))$

실전 배치 Task 1: 노드 분류 (Node Classification)

네트워크 내에 존재하는 개별 엔티티의 숨겨진 정체와 속성을 예측합니다.

- 개념: 라벨이 부여된 일부 노드의 정보를 바탕으로, 라벨이 없는 나머지 노드의 클래스를 식별.
- Transductive 학습: 전체 그래프 구조를 관찰하며 예측 수행.
- Inductive 학습: 훈련 시 보지 못했던 완전히 새로운 그래프나 추가된 노드에 대한 예측 수행.





GNN Encoder +
Log-Softmax Decoder

적용 사례: Elliptic AML (비트코인 자금세탁 탐지)


단일 노드의 피처가 은폐되더라도,
'이웃의 행동 패턴'은 정체를 드러냅니다.


- **데이터 세팅:** 비트코인 트랜잭션 네트워크 (Homogeneous Graph).
- **접근법:** GNN 인코더 + Log-Softmax 디코더 결합.
- **인사이트:** 자금 세탁 범죄자는 독립적으로 행동하지 않습니다. GNN은 불법적인 자금 흐름이 만들어내는 특유의 위상학적 군집(Topological cluster)을 식별해 냅니다.

실전 배치 Task 2: 링크 예측 (Link Prediction)

보이지 않는 관계를 재구성하거나, 미래에 발생할 연결을 확률적으로 예측합니다.

- 개념: 두 노드 u 와 v 사이에 엣지 e_{uv} 가 존재할 확률 $P(e_{uv} \in E)$ 을 추정.
- 응용: 친구 추천 시스템, 화합물 분자 결합 예측, 지식 그래프(Knowledge Graph) 추론 등.
- 핵심: 노드 개인의 특성뿐만 아니라, 두 노드가 공유하는 '구조적 컨텍스트'의 파악이 필수적입니다.





Topographic Network Map

심화 링크 예측: SEAL 프레임워크와 DRNL 라벨링


구조적 컨텍스트를 학습하기 위해
서브그래프(Subgraph)를 지형도처럼 모델링합니다.

- 1. 서브그래프 추출 (Enclosing Subgraph):**
타겟 노드 주변의 국소적 네트워크 경계 설정
- 2. 이중 반지름 노드 라벨링 (DRNL):**
거리 기반의 정수 라벨을 부여하여 타겟 노드와의
구조적 거리를 인코딩 (등고선 역할)
$$f_l(w) = 1 + \min(d_u, d_v) + (d/2)[(d/2) + d\%2 - 1]$$
- 3. 서브그래프 인코딩:**
라벨링된 구조를 GNN으로 학습하여 극대화된
링크 예측 성능 달성

적용 사례: MovieLens (이종 그래프 기반 추천 시스템)

서로 다른 속성의 엔티티를
연결하는 개인화된 링크지
(Linkage) 구축

- 데이터 세팅: 사용자(User)와 영화(Movie)가 혼재된 이종 그래프 (Heterogeneous Graph).
- 인코더 (H-GNN): 사용자와 영화 각각에 특화된 별도의 임베딩을 학습.
- 디코더 (Dot-Product): 사용자 벡터와 영화 벡터의 내적을 통해 상호 작용 확률 도출.
- 인사이트: 명시적 장르 특성뿐만 아니라 시청 패턴이라는 암묵적 구조를 동시에 캡처.



디코더 (The Decoders): 임베딩을 행동으로 번역하다

압축된 지식(임베딩)을 수학적 변환을 통해 최종 의사결정으로 투영(Project)합니다.



노드 분류 디코더:

단일 벡터의 다차원 확률 분포 변환
(Log-Softmax 사용, 극한값의 연산 안정성 확보).




링크 예측 디코더:

두 벡터 간의 기하학적 유사도 측정
(내적 연산 및 이진 교차 엔트로피 손실 함수 활용).

진실의 척도: 모델 성능 평가 지표

불균형한 실전 네트워크(예: 99%의 합법 거래와 1%의 자금세탁)에서 정확도(Accuracy)는 착시를 일으킵니다.




- Precision (정밀도): GNN이 '불법'이라고 지목한 노드 중, 실제 불법 노드의 비율은? (오경보 최소화)
- Recall (재현율): 전체 '불법' 노드 중, GNN이 성공적으로 포착해낸 비율은? (위험 탐지 극대화)
- F1-Score: 정밀도와 재현율의 조화 평균. 불균형 데이터 환경에서 모델의 진정한 신뢰성을 증명하는 핵심 지표.

통합 프레임워크: GNN 밸류 체인 (Value Matrix)

모든 구성 요소는 상호 교환 및 결합이 가능한 모듈식 아키텍처로 작동합니다.

데이터의 형태에 맞춰 인코더를 선택하고, 목표 태스크에 맞춰 디코더를 장착함으로써 어떠한 형태의 관계형 데이터도 가치 있는 통찰로 해독해 냅니다.



새로운 지평: GNN의 확장과 미래 패러다임



대규모 GNN
(Large-Scale GNNs)

슈퍼컴퓨터 기반 분산 학습. 수십억 개의 노드/엣지를 컷 엣지(Cut-edges) 통신 최적화를 통해 처리.



연합 GNN
(Federated GNNs)

원시 데이터 공유 없이, 로컬 그래프의 구조적 특성만 협력적으로 학습하는 프라이버시 보존형 AI.



LLM-GNN 통합
(Graph Foundation Models)

구조적 논리(GNN)와 시맨틱 추론(LLM)의 결합. 텍스트 속성 그래프의 희소성 극복 및 범용 제로샷 학습 달성.



그래프의 숨겨진 언어를 해독하다.
(Decoding the hidden language of graphs.)

Q&A