


제3의 AI 물결: 지식 그래프(KG)와 LLM의 결합 구조 설계

개발자 스터디를 위한 아키텍처,
데이터 파이프라인 및 구현 가이드
(Chapter 01)

[SYSTEM_ARCHITECTURE_BLUEPRINT]





LLM의 한계 (생성형 AI의 단점)



환각 현상 (Hallucinations)

정보의 부정확한 생성 및 사실과 다른 답변 출력




블랙박스 형태의 의사결정 (Explainability 부족)

AI의 추론 과정과 결과에 대한 설명 및 투명성 부족



도메인 특화 지식 및 최신 정보의 부재 (Stale Data)

학습 데이터의 최신성 부족 및 전문 지식 반영의 어려움



컨텍스트 및 관계에 대한 깊은 이해 부족

복잡한 문맥과 엔터티 간의 심층적인 관계 파악의 한계




KG의 한계 (전통적 지식 그래프의 단점)




구축 및 유지보수 비용 (시간, 노력, 자금)

지식 그래프의 초기 구축 및 지속적인 업데이트에 막대한 자원 소모



비정형 데이터(텍스트, 이메일) 처리의 어려움 (오타자, 대명사, 다국어)

다양한 형식의 비정형 데이터에서 구조화된 지식
추출의 복잡성 및 오류 발생




비전문가에게 진입 장벽이 높은 복잡한 쿼리 언어 및 탐색 패턴

전문 지식이 필요한 쿼리 작성 및 데이터 탐색의
난이도



결론: 미션 크리티컬 애플리케이션에는 정확성, 설명 가능성, 그리고 도메인 지식이 필수적이다. 단일 기술로는 한계가 명확하다.


Core Concept: 지식 그래프(KG)의 데이터 구조 해부




요약

KG는 구조화되고 검증 가능하며 업데이트 가능한 지식 표현을 제공하여 머신이 추론(Reasoning)과 추론(Inference)을 수행할 수 있게 한다.

The Killer Combination: 상호 보완적 시너지 매트릭스



하이브리드 아키텍처 설계를 위한 4가지 시스템 요구사항



EVOLUTION (진화)

중단 없는 데이터 수집 파이프라인.
전체 구조 개편 없이 새로운 노드/엣지를
동적으로 추가할 수 있는 유연성.



SEMANTICS (의미론)

타입화된 엔티티와 명시적 관계로 모델링.
일관성 검사 및 인과 추론을 위한 시맨틱 레이어.



INTEGRATION (통합)


정형/비정형 데이터를 아우르는 단일 진실
공급원(Single Source of Truth).
데이터 사일로 통합(McKinsey: 데이터 비용 5~15% 절감).



LEARNING (학습)

그래프 쿼리, 시각화, 그리고 머신러닝(Graph
Neural Networks 등)을 통한 새로운 패턴 추론.

High-Level Architecture: LLM-KG 하이브리드 인텔리전트 시스템



Key Takeaway: 지능형 행동을 고유한 신뢰 출처(KG)에 한번만 인코딩하여 다양한 애플리케이션에서 재사용하는 패러다임 전환.

Implementation Flow 1: Data Ingestion (KG 구축 경로)



입력

이메일, 채팅, 문서 등 비정형 데이터 처리.
(기존 방식: 복잡한 커스텀 NLP 모델 필요).

LLM 처리

LLM을 다목적 정보 추출기로 활용.
프롬프트(Prompt)만 변경하여
도메인 관련 개념 및 연결 추출.

매핑

추출된 데이터를
타겟 그래프 스키마로 변환.

[Code Application Point]

1
2
3

엔티티 및 관계 추출을 위한 프롬프트 엔지니어링 및 JSON 스키마 강제(Enforcement) 기법.

Implementation Flow 2: Graph Query & Retrieval (읽기 경로)

Step 1: 질문 변환
LLM이 사용자의 자연어 질문을
해석하여 정확한 그래프 쿼리
(Text-to-Cypher / SPARQL)로 변환.



Step 2: 정보 검색
멀티 홉(Multi-hop) 쿼리를 통해 KG에서
신뢰할 수 있는 사실 기반 정보를 추출.
Vector 유사도 검색 병행 가능.

Step 3: 응답 생성
KG에서 반환된 정형 데이터를
LLM이 다시 자연어로 합성,
요약하여 사용자에게 제공.

Tech Stack Decision Matrix: 데이터베이스 계층 선택 (RDF vs. LPG)


RDF (W3C 표준)	LPG (Labeled Property Graphs)
✓ 포커스: 지식 표현, 시맨틱 일관성, 웹 스케일 상호 운용성.	✓ 포커스: 그래프 구조, 속성, 효율적인 그래프 순회(Traversal).
✓ 데이터 모델: 트리플(Triplets) 구문 (주어-동사-목적어).	✓ 데이터 모델: 노드와 엣지 자체가 고유한 식별자와 속성(Properties)을 가짐.
✓ 쿼리 언어: SPARQL.	✓ 쿼리 언어: openCypher, Gremlin.
✓ 장점: 글로벌 프레디케이트(Predicate) 재사용, 온톨로지 기반 지식 추론, 연합(Federation) 쿼리.	✓ 장점: 경로 탐색(Pathfinding) 쿼리, 풍부한 속성 기반 데이터 표현.

전제 조건: 단순한 구조적 연결만으로는 데이터 내의 내재적 관계를 완전히 포착할 수 없음.

시맨틱 레이어 설계: Taxonomies vs. Ontologies

Semantic Scale


Taxonomies - 분류 체계



데이터의 계층적 차원. 넓은 개념에서 좁은 개념으로 카테고리화.

예: Vehicle -> Car -> Sedan

Ontologies - 온톨로지




단순 계층을 넘어선 복잡한 관계. 동의어(Identity), 차이(Disjointness), 카디널리티 등 논리적 규칙 정의.

예: 'Car'와 'Automobile'은 동일, 'Car'와 'Bicycle'은 상호 배타적

Developer Precaution 1: "Just Enough Semantics" (안티 패턴 주의)

Warning / Anti-Pattern



문제점: 전통적인 방식처럼 처음부터 완벽하고 엄격한 온톨로지를 정의하려 하면 시스템이 경직되고, 다양한 데이터 소스와 진화하는 지식에 적응하지 못함.

Success / Best Practice



해결책: "Just Enough Semantics"
(딱 필요한 만큼의 시맨틱) 적용.

실천 방안:

- ✓ 1. 현재의 문제를 해결하는 온톨로지 기능의 하위 집합만 우선 선택.
- ✓ 2. 특정 도메인(예: 종양학, 심장학)부터 시작하여 유기적으로 확장.
- ✓ 3. 유연하고 확장 가능한 동적 지식 표현 구조 유지.

Developer Precaution 2: LLM 비결정성(Non-Determinism) 제어

⚠ **위험 요소:** 데이터 추출 과정에서 LLM은 환각을 일으키거나
일관되지 않은 형식의 데이터를 출력할 수 있음.
(잘못된 데이터 = 잘못된 KG).

Schema Validation Gate

[Code Application Point]

- 무결성 검증 파이프라인 필수 구축.
- 추출된 엔티티가 기존 타겟 스키마(Target Schema) 및 시맨틱 규칙(Ontology)에 정확히 매핑되는지 확인.
- 단순한 프롬프팅에 의존하지 않고, Function Calling 및 JSON 스키마 강제 기능을 활용하여 구조화된 출력 보장.

Architectural Trade-offs: 언제 하이브리드(KG+LLM)를 도입해야 하는가?

KG 도입이 필요한 경우

분산된 데이터 사일로를
일관되게 조화시켜야 하는가?

ON

데이터 파이프라인의 출처(Provenance)와
일관성 추적이 필요한가?

ON

네트워크 구조 시각화 및 노드 간
종속성 파악이 중요한가?

ON

LLM 도입이 필요한 경우

비정형 텍스트에서 엔티티/관계를
자동 추출해야 하는가?

ON

복잡한 사용자 질의를 정확하게
해석해야 하는가?

ON

대화형 인터페이스(Conversational AI)
및 텍스트 요약이 필요한가?

ON

결론: 두 목록 중 하나라도 해당한다면,
KG 솔루션을 **강화**하기 위해 **LLM**이 필요하다.

Use Case Deconstruction: 고객 지원 대화형 AI 시스템




도전 과제: 단순 NLG(자연어 생성) 모델은 반복적이고 정보가 부족한 답변을 생성함.

하이브리드 아키텍처의 해결책:

- **Knowledge Graph:** 대화의 맥락이 되는 '개념'들을 연결. 기업의 내부/외부 정형 지식을 통해 대화의 흐름(Context)을 그라운드.
- **LLM:** 자연스러운 인터페이스 제공. KG에 저장된 구조화된 정보(고객 이력, 제품 매뉴얼)를 활용하여 구체적이고 정확한 답변 생성.

결과: 일반적인 챗봇의 한계를 넘어, 깊이 있고 문맥에 맞는 전문적인 상담 제공.

Developer Action Plan (다음 스터디를 위한 준비)



Footer: 기반 기술(Part 1) 구축 완료. 다음 장에서는 지식 표현 및 추론 전략 심화 학습 진행.