



```
> cd chapter_03
```

03. 온톨로지 기반 지식 그래프 구축

개발자 스터디 그룹을 위한 실전 구현 가이드

Status: [READY]

목표 (The Goal)



희귀 질환(Rare Diseases)
진단을 돕는 임상 지원
도구 구축.

환자의 복합적인
표현형(증상)을 기반으로
숨겨진 질환을
찾아내는 시스템.

데이터 (The Data)



- **hp.owl**: 표준화된 인간
표현형 온톨로지
(RDF/XML 포맷).
- **phenotype.hpoa**:
질환과 표현형의 매핑
메타데이터가 담긴 주석
파일 (TSV 포맷).


기술 스택 (The Tech)



Neo4j, Cypher,
Neosemantics(n10s),
APOC.

속성 및 메타데이터 관리에
최적화된
LPG(Labeled Property
Graph) 기반 그래프
데이터베이스.


Knowledge Graph 구축을 위한 CRISP-DM 방법론





```
1 obo:HP_0100651 a owl:Class ;  
2   rdfs:label 'Type 1 diabetes mellitus' ;  
3   rdfs:subClassOf obo:HP_0000819 ;  
4  
5  
6  
7  
8  
9 obo:HP_0100651 a owl:Class ;  
10  rdfs:label 'Type 1 diabetes mellitus' ;  
11  rdfs:subClassOf obo:HP_0000819 ;  
12
```

제1형 당뇨병 식별자




핵심 개념: 온톨로지는 데이터를 주어(Subject), 서술어(Predicate), 목적어(Object)의 ‘트리플(Triple)’ 형태로 모델링하여 이질적인 데이터를 통합하는 중간 매개체 역할을 합니다.

아키텍처 결정: RDF vs. LPG

구분 (Category)	RDF (Resource Description Framework)	 LPG (Labeled Property Graph)
철학 (Philosophy)	웹 상의 의미론적 데이터 교환 및 온톨로지 구축 표준 (W3C).	빠른 경로 탐색 및 그래프 데이터 순회(Traversal) 중심.
엣지 속성 (Edge Properties)	글로벌 서술어. 엣지(관계) 자체에 메타데이터를 직접 부여하기 어려움.	엣지에 직접 Key-Value 형태의 속성(Properties)을 네이티브하게 저장 가능.
쿼리 언어 (Query Language)	SPARQL	Cypher


표현 방식의 차이: 메타데이터 처리

RDF의 한계와 우회법 (N-ary Relation 표현의 난해함)



RDF는 엣지에 속성을 달기 위해 '빈 노드(Blank Node)'를 생성하거나 RDF-star 확장을 사용해야 함.
→ 구조적 복잡도 증가 및 성능 저하 우려.

LPG의 네이티브 해결책 (Edge Property의 직관적 처리)



LPG는 관계 자체에 메타데이터를 직접 저장.
임상 데이터의 출처(Provenance) 및 이력 추적에 압도적으로 유리함.

구현 1단계: 온톨로지 데이터 적재 (n10s)

```
CALL n10s.graphconfig.init();  
CALL n10s.graphconfig.set({  
  handleVocabUris: 'IGNORE'  
});  
CALL n10s.graphconfig.set({  
  applyNeo4jNaming: True  
});
```

```
CALL n10s.rdf.import.fetch('http://purl.obolibrary.  
obolibrary.org/.../hp.owl', 'RDF/XML');
```


복잡한 네임스페이스를 무시
하여 데이터 모델을 단순화.

관계형 타입을 대문자로
변환하여 네이티브 LPG 표준
네이밍 컨벤션을 따름.


약 90만 개의 트리플 데이터를
파싱하여 Neo4j로 한 번에 로드.

구현 결과 1: 온톨로지 및 도메인 데이터 통합

온톨로지 메타 정보 (정의, 동의어 등 개념적 설명)



도메인 특화 정보 (실제 질환 간의 계층 구조)



Neosemantics를 통해 단일 파일에서 온톨로지 구조와 실제 의료 도메인 데이터가 하나의 그래프로 완벽히 통합 적재됨.

구현 2단계: 어노테이션(TSV) 데이터 통합

disease	phenotype	author	date
OMIM:222100	HP:0410050	Nicole V...	2018-02-23


```
LOAD CSV FROM '.../phenotype.hpoa' AS row  
FIELDTERMINATOR '\t'
```

```
MATCH (dis:HpoDisease) WHERE dis.id = row[0]  
MATCH (phe:HpoPhenotype) WHERE phe.id = row[3]
```

```
MERGE (dis)-[:HAS_PHENOTYPIC_FEATURE]->(phe)
```

- LOAD CSV: 대용량 TSV 파일을 순회.
- MATCH: 앞서 적재한 질병 노드와 표현형 노드를 탐색.
- MERGE: 중복 생성을 방지하며 두 노드 사이를 연결하는 관계 엣지 생성.

데이터 변환 모델: 테이블에서 그래프로



테이블의 행(Row) 하나가 그래프의 풍부한 **엣지**(Edge Property)로 치환되는 물리적 과정.

구현 3단계: 속성 데이터 예외 처리 및 정제

Resilient Edge Properties (결측치 처리)

```
FOREACH(_ IN CASE WHEN row[4]  
is not null THEN [1] ELSE []  
END |  
  SET rel.source = row[4])
```

TSV의 결측치(NULL)로 인해 기존 데이터가 덮어쓰워지는 것을 방지하는 Cypher 트릭. 값이 존재할 때만 배열 요소를 반환하여 안전하게 SET 실행.

Graph Cleanup (메모리 최적화)

```
CALL apoc.periodic.iterate(  
  'MATCH (n) ...',  
  'DETACH DELETE n',  
  {batchSize:10000}  
)
```

APOC 라이브러리를 사용하여 대용량 그래프에서 불필요한 온톨로지 찌꺼기 노드를 배치(Batch) 단위로 안전하게 삭제.

활용 1: 직접 질의를 통한 교차 탐색

환자 증상 체크리스트

- ✓ Growth delay (성장 지연)
- ✓ Large knee (무릎 비대)
- ✓ Sensorineural hearing impairment (감각신경성 난청)
- ✓ Pruritus (가려움증)
- ✓ Type I diabetes mellitus (제1형 당뇨병 병력)


쿼리 및 결과

```
MATCH path=(dis)-[:HAS_PHENOTYPIC_FEATURE]->(phe)
WHERE phe.label IN ['Growth delay', ...]
RETURN ...
```

disease_id	disease_name	num_of_features
OMIM:619269	Ondotochondrodysplasia 2...	5
OMIM:618500	Holoprosencephaly 12...	3

단순한 RDBMS 조인이 아닌, 여러 표현형 노드와 동시에 연결된 중심 질환 노드를 직관적으로 탐색.

진정한 가치: 온톨로지 기반 의미론적 추론 (Semantic Reasoning)



임상의가 '내분비계 이상'이라는 상위 개념만 검색해도, 그래프의 SUBCLASSOF 계층 구조를 타고 내려가 명시적으로 연결되지 않은 하위 질환까지 **자동으로 추론(Inference)**하여 반환합니다.

추론 쿼리 구현 (Reasoning in Code)

```
MATCH (p:HpoPhenotype {label: 'Abnormality of the endocrine system'})  
MATCH (p) <-[:SUBCLASSOF*1..3]- (n:HpoPhenotype)  
MATCH (n) <-[:HAS_PHENOTYPIC_FEATURE]- (d:HpoDisease)  
RETURN d.label
```

가변 길이 경로(Variable-length path):
지정된 상위 노드로부터 1~3단계 하위에 있는
모든 서브클래스 표현형을 한 번의 쿼리로 순회.
Cypher와 그래프 DB의 가장 강력한 기능 중 하나.

disease	features
Congenital atransferrinemia	... Hypothyroidism

⚠ 개발자 주의점 및 요약 (Developer Caveats)

[WARN] 네임스페이스 관리: 온톨로지가 진화함에 따라 하위 호환성 문제가 발생할 수 있습니다. Ingestion 단계에서 접두사(Prefix) 처리 전략을 명확히 정의해야 합니다.

[WARN] 그래프 오염 방지: 주기적으로 `apoc.periodic.iterate`를 활용하여 고립된(Orphan) 노드와 불필요한 메타데이터 엣지를 정제(Cleanup)해야 쿼리 성능이 유지됩니다.

[OK] 아키텍처 결론: 데이터의 '출처(Provenance)'와 메타데이터 추적이 중요한 도메인(의료, 금융 등)에서는 순수 RDF보다 LPG + Cypher 조합이 개발 효율성 측면에서 압도적으로 유리합니다.

> exit