


```

raw_data = {...}
log: 2024-05-15 10:30:01 [INFO] process started...
unstructured_text = "This is a long block of text ..."
unstructured_text = "This is a long block of text ..."
unstarsaved_raw_names = [...]
json_blob = {'key': 'value', 'nested': [...]}
error_log: [WARN] missing parameter ... "
log: 2020-5720-1379128133 [INF] proces sstarted ...
json_blob = [WARN] parameter is event to p-nseme
raw_data = {'json data 'SF errors dAW' }
error_log: [WARN] missing parameter..."
time: 2024-05-15 10:30:01 [INFO] sleating noded...
unstructured_text = 'value', 'nested': [...]}
log: 2024-05-15 10:30:01 [INFO] process started with ...
unstructured_text = "This is a long block of
unstructured_text = "This is a long block of text..."
Relationship : (Author of)
json_blob = {'key': 'value', 'nested': [...]}
error_log: [WARN] missing parameter
raw_blob = {'key': 'value', 'Data Point Z
raw_data = {...}

```




Code to Graph: 비정형 데이터의 지식 그래프화

LLM과 프롬프트 엔지니어링을 활용한 실무 구축 가이드 (Chapter 05)

개발자 스터디용 아키텍처 및 구현 분석

80%의 비정형 데이터, 그리고 아카이브의 딜레마



문제 상황

기업 데이터의 80~90%는 이메일, 회의록, 과거 문서 등 비정형 텍스트로 존재합니다.

록펠러 아카이브(RAC) 사례

지원금 승인 기록, 타자기록, 은어가 섞인 프로그램 책임자의 일기(Diary)에서 유의미한 패턴 추출 필요.

최종 목표

단순 검색을 넘어, 특정 아이디어가 자금 지원을 받기 전의 패턴과 같은 복잡한 질문에 답하기 위해 검증 가능한 구조화된 지식(Knowledge)으로 변환.



1. NER (개체명 인식)


원시 텍스트에서 개체(Entity)를 식별하고 사전 정의된 범주로 할당하는 과정.

2. RE (관계 추출)

개체 쌍 간의 의미론적 관계(Semantic Relation)를 식별하고 일관성 있는 방향성을 부여.


아키텍처의 진화: 전통적 NLP 파이프라인 vs LLM

전통적 모델 중심 (Model-Centric) 접근



매우 복잡하고 종속적인 파이프라인, 막대한 초기 비용 발생.

LLM 중심 (Data/Prompt-Centric) 접근




사전 학습된 가중치 재사용, 모델 학습 없이 즉시 결과 도출.

LLM의 숨겨진 강점: 암시적 상호참조 해결




전통적 NLP는 '대명사 인식 -> 본명 매칭 -> 관계 추출'의 3단계가 필요하지만, LLM은 문맥을 이해하여 한 번의 추론으로 완벽히 정규화(Normalization)합니다.


텍스트에서 그래프로: 전체 구현 워크플로우



Prompt V1: 범용적 접근의 한계와 정규화 문제



단순한 Task 부여: 모델이 모든 것을 스스로 판단하도록 방치.



The Normalization Problem:
의미론적으로 동일한 관계를 4개의 다른 엣지로
파편화하여 추출. 향후 Cypher 쿼리 검색 시
치명적인 시스템 복잡성을 유발함.


Prompt V2: 스키마 주입(Schema Injection)을 통한 정규화

The Diff

```
git/rmsqls.git
... @@ -1,2 +35 @@
1 {
2 + Entity Classes:
3 +   [Person, Organization, Topic, Location]
4 + Relation Classes:
5 +   [WORKS_FOR, WORKS_ON, TALKED_ABOUT]
6 }
```

개선점: 모델이 선택할 수 있는 정답지(Schema)를 강제로 주입.

The Result



개선 효과:

- 출력값이 단일 엮지로 완벽히 정규화됨.
- 사람의 이니셜(R. -> Rossby) 등 도메인 특화 지침 추가로 예측 안정성 향상.

Prompt V3: 복잡한 예제(Few-Shot) 제공과 안정화

최적화 기법: Few-Shot 하드코딩

실제 데이터에서 모델이 헛갈려 하는 가장 복잡한 언어적 구조(엣지 케이스)를 포함한 대표 예제 1~2개를 프롬프트에 직접 주입. 출력 형식을 JSON 배열로 고정.

```
[
  {
    "subject": "D.H. Andrews",
    "subject_type": "Person",
    "relation": "TALKED_ABOUT",
    "object": "J.B. Mayer",
    "object_type": "Person",
    "properties": {
      "sentiment": "positive",
      "title": "Professor of Chemistry"
    }
  }
]
```

완벽한 매핑 및 속성 추출 성공

주의점 1: 생성형 모델의 불안정성과 온도(Temperature)

LLM은 본질적으로 생성 모델이므로, 동일한 텍스트와 프롬프트라도 실행 시점의 '기분(Mood)'에 따라 결과가 달라집니다.

Run 1 (정상)



Run 2 (환각 및 누락)



개체 누락 및 관계 추출 실패

실무 가이드: 사실 관계 추출(Fact-focused task) 시 반드시 Temperature = 0으로 설정하여 결정론적(Deterministic) 출력을 유도할 것.

개발자를 위한 실무 검증 프레임워크



1. 프롬프트 단위 테스트

프롬프트를 코드처럼 취급합니다. '텍스트 스니펫'과 '기대하는 '기대하는 JSON 출력값'을 테스트셋으로 구성하고, 수정 시마다 자동 평가를 돌려 회귀(Regression)를 방지합니다.



2. 미니 KG 시각화 검수

수십 페이지 분량의 샘플로 '미니 지식 그래프'를 시각화하여 육안 검수(Eyeballing)를 진행합니다. 축약어 등 시스템적 오류를 즉각적으로 식별할 수 있습니다.



3. LLM as a Judge


휴먼 QA 외에도, 다른 강력한 LLM을 평가자로 활용합니다. 추출된 데이터의 Precision, Recall, F1 Score를 자동화하여 평가합니다.

아키텍처 결정 매트릭스: 어떤 기술을 선택할 것인가?

평가 항목	전통적 NLP	대형 언어 모델 (LLMs)
예측 속도 (Prediction Speed)	✓ 빠름 (CPU 가능)	✗ 느림 (대규모 모델)
인프라 / 예측 비용	✓ 매우 낮음	✗ 높음 (GPU 필수)
초기 도메인 커스텀	✗ 오래 걸림 (데이터 어노테이션)	✓ 매우 빠름 (Transfer Learning)
보안 (Security/On-prem)	✓ 사내 폐쇄망 구축 용이	✗ 폐쇄망 구축 시 막대한 GPU 비용

Takeaway: 소규모~중규모 데이터와 빠른 PoC 도입은 LLM. 실시간 스트리밍, 방대한 대규모 데이터, 철저한 보안이 필요할 때는 전통적 NLP가 유리합니다.

패러다임의 전환: 데이터 중심 AI (Data-Centric AI)



Garbage in, Garbage out. 결국 양질의 데이터와 프롬프트가 모델을 이깁니다.

하이브리드 블루프린트: 두 기술의 공존

LLM
(초기 구축)

강력한 추론 능력으로
방대한 비정형 데이터에서
초기 학습 데이터를
초고속 사전 어노테이션(Pre-
annotation).

전통적 NLP
(프로덕션 배포)

정제된 데이터로
가벼운 NLP 모델을 학습.
비용, 속도, 보안을
최적화하여
실제 서비스에 배포.

휴먼 인더 루프
(검수 및 보정)

결론: 두 기술은 배타적이지 않습니다. LLM의 창의성으로 '지식의 뼈대'를 세우고,
NLP의 효율성으로 '프로덕션'을 완성하십시오.