


LLM과 지식 그래프(KG)의 결합: 아키텍처 및 구현 가이드

비정형 데이터 정제부터 엔티티 리졸루션, 그래프 분석까지



Developer Study Guide: Chapter 06

아날로그 비정형 데이터의 한계

Before
ANALOG UNSTRUCTURED DATA (비정형 아날로그 데이터)

1 비표준 언어 관행:
'S.' 대신 'J.R.
Smith', 'U.Cal.'
대신 'University of
California'. 기존
NLP의 공지시어
해결(Coreference)
실패.

The tech-precision sam/er affiliates of the certainties
present and affiliation in name sa J.R. Smith and lead
writer: 'S.' → 'J.R. Smith', 'U.Cal.' → 'University of
California' → 'University of California' in first-act came documentalm;
Lead writers and Enginen recently written during to this
project relations sp segatue as-ornacle/teisties ce-lmab's
university faciate to-unioie poseile with anckests both monien
asloert.


The test-empnsiion bobet/carily was-d: oached doromatchy
nonaveined data in the oxpen notine ceepitotieig innoivation
with tn specialized terms (erlest, inidosttr, insetructine,
wsting some ie-sqlste rekiote-olth the evaluated sceskion:lol
carke, on-an ensemled tk esplish compexes, specialised terms:
the require aerera-reata licenss, she night-understosailay
monitions siko-dur and preces-ed aerivt ertms directors ty
Project Alpha.

The cuclst project is terghuey prgiest seqlen of
informaine mkm meripm and re anreogates as sonal-posteo
reportboy. Presenters coop-test Personnel, bella project and
Secossexs serbe as Exhibits some-coach mardines-reperndiny
saphk. This heve to befinel sep-sesamiss and enecetis re
eak:contines spie:/destoier and intereacate spita and
rcoject-sop size-up in 2020 in the merte-and iofra-stroence;
and-auekines bp:seroserece reasessat-dieras alioasing
operating opetens so factured that increase solis neslid
researex, interesting and masee goosereetens ail setes:

2 도메인 특화 엔티티:
사전(Dictionary)이나
학습된 NER 모델 부재.


3 높은 관계 복잡도:
단일 페이지에 수십 개의
복잡한 관계 존재.

After
STRUCTURED KNOWLEDGE (구조화된 지식)




LLM의 암시적 NER 및 관계 추출(RE)을
활용하여 혼란을 구조화된 지식으로 변환

KG 구축 파이프라인



핵심 인사이트: 과거에는 막대한 비용의 전통적 ML 파이프라인이 필요했지만, 현재는 적절한 프롬프트 엔지니어링과 LLM으로 상당 부분을 대체 가능합니다.

3계층 그래프 아키텍처



최종 KG 계층 (Final KG Layer):
최종 정규화 및 병합(Resolved)이 완료된
도메인 엔티티와 의미론적 관계.

메타그래프 계층 (Metagraph Layer):
LLM이 추출한 '병합되지 않은' 원본
엔티티 멘션. 데이터 출처(Origin)
추적 및 보존의 핵심.

문서 계층 (Document Layer):
초기 데이터 수집.
최종 정제된 페이지 텍스트가 속성으로 저장됨.

정규화 및 데이터 클렌징

```
MATCH (p:Person)-[:HAS_TITLE]->(t:Title)
SET p.name = trim(replace(p.name, t.name, ''))
```

직함 제거: 인물 노드의 중복 생성 방지. LLM이 직함을 이름의 일부로 잘못 포함한 경우, 이를 분리하여 깨끗한 정규형(Canonical form) 생성.


```
MATCH (o:Occupation)
SET o.name = toLower(o.name)
```

소문자화: 대소문자 차이로 인한 그래프 단절 방지. 후속 클러스터링을 위한 일관성(Consistency) 확보.

엔티티 리졸루션 신호 매트릭스

신호 유형 (Signal Type)	방법 (Method)	예시 (Example)
문자열 유사성 (String Similarity)	규칙 기반 텍스트 매칭. 성(Surname) + 이름/약어 조합 필터링.	'Eleanor Smith' ↔ 'E. Smith'. (주의: Foundation 등 제네릭 단어는 Stopword 처리 필수)
그래프 토폴로지 (Graph Topology)	홉(Hop) 거리 및 공유 관계 분석.	이름이 유사한 두 노드가 동일한 대학교와 WORKS_FOR 관계를 맺고 있으면 병합 신뢰도 급상승.
그래프 머신러닝 (Graph ML)	임베딩 클러스터링 및 커뮤니티 탐지(Louvain).	문자열 유사성이 없어도(예: 'fertility' ↔ 'human ovulation') 의미론적 임베딩이 유사하면 연결.



토폴로지 기반 리졸루션: 'Ernest Lawrence' 은유



핵심: RDB에서는 6-hop 거리를 횡단하여 동일 인물임을 유추하기 매우 어렵습니다. 지식 그래프는 노드 간의 공유된 관계(직장, 연구 주제)를 바탕으로 분절된 엔티티를 하나로 당기는 위상적(Topological) 중력을 생성합니다.


핵심 설계 패턴: 메타그래프와 WCC 알고리즘

1. 메타그래프 (원본 보존)



2. WCC (Weakly Connected Components)

Ernest Orlando Lawrence




LLM의 출력을 즉시 병합하지 않고 원본 텍스트와의 연결고리(Lineage)를 유지합니다.

WCC 알고리즘으로 연결된 멘션 그룹을 식별하고, 그룹 내 가장 긴 이름을 최종 정규 노드로 선택하여 단일 엔티티로 병합합니다.


지적 네트워크 분석: 토폴로지의 가치

The Influencer (PageRank)



페이지랭크(PageRank) - 타인의 연구를 추천하거나, 타인에게 자주 언급되는 핵심 인물 도출.

The Bridge (Betweenness)




매개 중심성(Betweenness Centrality) - 서로 단절된 연구 커뮤니티를 연결하는 브릿지 역할 탐색. 최단 경로가 집중되는 병목 노드.

실전 쿼리: 대학 간 물리 | 네트워크 탐색

MATCH p=(p1:Person)-[*1..3]-(p2:Person)

가변 길이 경로를 사용하여 최대 3-hop 이내의
간접적인 '소개(Referral)' 패턴 탐색.




결과: 특정 도메인에서 두 거대 기관을 이어줄 수 있는 비공식적 커넥터를 즉시 식별 가능.

개발자 주의사항: LLM 환각(Hallucination) 현상

오류 원인 및 해결책

- **추출 오류:** GPT가 페이지 내 'Ernest Lawrence'의 존재로 인해 혼동을 일으켜, 생리학자인 'Laurence Irving'의 이름을 잘못 표기하고 사이클로트론 네트워크에 잘못 편입시킴.
- **아키텍처 원칙:** LLM은 마법이 아닙니다. 자동화된 파이프라인에는 반드시 분석가가 KG 콘텐츠를 검증할 수 있는 인간 개입 피드백 루프(Human-in-the-loop)가 설계되어야 합니다.



아키텍처 트레이드오프: LLM 단독 vs LLM + 지식 그래프

	Direct LLM (LLM 단독)	LLM + Knowledge Graph
설명 가능성 (Explainability)	블랙박스 (환각 발생 시 원인 추적 불가)	메타그래프를 통한 100% 추적 가능성. 원본 문서 라인까지 검증 가능
비용 및 대중화 (Cost & Democratization)	모든 쿼리마다 막대한 토큰 비용 발생	추출 시 1회성(One-time) 비용 발생. 이후 그래프 쿼리는 매우 저렴
고급 분석 (Advanced Analytics)	텍스트 기반 답변에 국한됨	페이지랭크, 커뮤니티 탐지 등 수치 기반의 그래프 데이터 과학(GDS) 적용 가능

결론: LLM 시대의 지식 그래프

탈-블랙박스화 (Demystification)

AI를 맹목적으로 신뢰하는 대신, LLM의 언어 이해력을 '추출 도구'로만 사용하여 사실 기반의 확신(Confidence)을 확보합니다.

탐색 가능성 (Explorability)

전역적 뷰(Global view)와 드릴다운(Drill-down) 조사를 동시에 제공하여, 분석가가 직접첩 가설을 세우고 검증하도록 영감을 줍니다.

분석의 기반 (Analytics Foundation)

단순한 Q&A 시스템을 넘어, 데이터 과학자가 후속 머신러닝 및 네트워크 분석을 수행할 수 있는 완벽한 통제권을 제공합니다.

LLM은 데이터를 읽어내고, 지식 그래프는 그 데이터를 신뢰할 수 있는 지체로 만듭니다.